ПСМО ФКН ВШЭ, 3 курс, 2 модуль

Задание 4. Регрессия. Моделирование выборок. Бутстреп.

Прикладная статистика в машинном обучении, осень 2019

Время выдачи задания: 8 декабря.

Срок сдачи: **23 декабря (понедельник), 23:59.**

Среда для выполнения практического задания – PYTHON 2.x/PYTHON 3.x.

Правила сдачи

Инструкция по отправке:

1. Решения задач следует присылать единым файлом формата `pdf`, набранным в LaTeX, либо в составе ipython-тетрадки в форматах `ipynb` и `html` (присылайте оба формата, т.к. AnyTask из-за высокой загрузки иногда не рендерит тетрадки в формате `ipynb` – а если мы не увидим ваши задачи, мы их не проверим). Отправляйте практические задачи в виде отдельных файлов (ipython-тетрадок или исходных файлов с кодом на языке `python`).

Оценивание и штрафы:

1. Максимально допустимый набранный балл за все задания – 17 баллов.

2. Оценка за домашнее считается как $\min(10, \text{набранный балл})$.

3. Бонусные баллы считаются как $\max(0, \text{набранный балл} - 10)$.

4. Дедлайн жесткий. Сдавать задание после указанного срока сдачи нельзя.

5. Задание выполняется каждым студентом индивидуально и независимо от других студентов. «Похожие» решения считаются плагиатом и все студенты (в том числе те, у кого списали) не могут получить за него больше 0 баллов, причем обнуляются и бонусные баллы. Если вы нашли решение какого-то из заданий (или его часть) в открытом источнике, необходимо указать ссылку на этот источник в отдельном блоке в конце вашей работы (скорее всего вы будете не единственным, кто это нашел, поэтому чтобы исключить подозрение в плагиате, необходима ссылка на источник).

Основные задачи

1. (4 балла) Воспроизведите часть результатов построения доверительных интервалов для оценивания интенсивности пуассоновского потока событий в наличии мешающего параметра. Пусть

$$N \sim \text{Poisson}(\theta + \nu)$$

наблюдаемая случайная величина (число реализаций пуассоновского потока событий при наличии *сигнала* в данных), где θ – интересующая нас интенсивность пуассоновского потока сигнала, а ν – интенсивность *мешающего* пуассоновского потока *фоновых* событий. Для определения интенсивности ν делается дополнительное измерение

$$K \sim \text{Poisson}(\tau\nu)$$

с известной постоянной τ. Задача – построить доверительные интервалы для θ.

   - Рассмотрите ряд значений $\theta_i = \Delta i$, где $\Delta = 0.1$, $i = 1, \ldots, 200$. Возьмите фиксированные значения $\nu = 1$ и $\tau = 1$.
   - Смоделируйте выборку объема 100 измерений сигнала (случайной величины N) и 1000 измерений фона (случайной величины K).
   - Рассмотрите следующие методы построения доверительных интервалов: Exact likelihood ratio test inversion, Asymptotic LR Test Inversion, Simple Percentile Bootstrap, Automatic Percentile Bootstrap.
   - Для каждого из рассматриваемых методов и для каждого значения θ_i постройте 95% доверительный интервал для оценки $\widehat{\theta}$.

- В ответе приведите для каждого метода описание процедуры расчета доварительных интервалов и графики построенных доверительных интервалов в сравнении с истинным 95% доверительным интервалом для среднего значения $\mathbb{E}\theta$.

2. (2 балла) Пусть $T_n = \bar{X}_n^2$, $\mu = \mathrm{E}(X_1)$, $\alpha_k = \int |x-\mu|^k dF(x)$ и $\hat{\alpha}_k = \sum_{i=1}^{n} \left|X_i - \bar{X}_n\right|^k$. Докажите, что оценка дисперсии функционала T_n с помощью бутстрепа равна:

$$v_{boot} = \frac{4\bar{X}_n^2\hat{\alpha}_2}{n} + \frac{4\bar{X}_n\hat{\alpha}_3}{n^2} + \frac{\hat{\alpha}_4}{n^3} + \frac{\hat{\alpha}_2^2(2n-3)}{n^3}$$

3. (2 балла) Пусть есть выборка из 11 элементов: $x_{(1)} < x_{(2)} < x_{(3)} < x_{(4)} < x_{(5)} < x_{(6)} < x_{(7)} < x_{(8)} < x_{(9)} < x_{(10)} < x_{(11)}$. Оцениваемая статистика θ – медиана.

   1. Покажите что для оценки $\hat{\theta}$ по бутстрепной выборке верно следующее:

$$P(\hat{\theta} > x_{(i)}) = \sum_{j=0}^{5} Bi\left(j, n, \frac{i}{n}\right),$$

   где $Bi(j; n, p) = C_n^j p^j (1-p)^{n-j}$.

   2. Покажите что оценка $\hat{\theta}$ по бутстрепной выборке равна $x_{(i)}$ с вероятностью:

$$P\left(\hat{\theta} = x_{(i)}\right) = \sum_{j=0}^{5}\left(Bi\left(j; n, \frac{i-1}{n}\right) - Bi\left(j, n, \frac{i}{n}\right)\right),$$

   3. Используя результат пункта (1) выведите 90% бутстрепный доверительный интервал для медианы (подсказка: подсчитайте $p(\hat{\theta} \geqslant 3)$ и $p(\hat{\theta} \geqslant 9)$).

4. (3 балла) Рассмотрим данные по адресу https://vincentarelbundock.github.io/Rdatasets/csv/MASS/galaxies.csv, описывающие скорости 82 галактик из созвездия Северной Короны. Мы хотим узнать, есть ли пустоты или суперкластеры в данной части вселенной. Одним из свидетельств является мультимодальность распределения скоростей галактик. Другими словами, нам необходимо проверить гипотезу унимодальности распределения, т.е.:

$$H_0 : n_{mode}(p) = 1 \text{ vs } H_a : n_{mode}(p) > 1$$

Плотность распределения будем оценивать напараметрическим ядерным методом:

$$\hat{p}_{K,h}(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right)$$

(a) По данным найдите минимальное $\hat{h}_{uni}$ при котором распределение ещё унимодально.

Найденная $\hat{h}_{uni}$ является оценкой по данным для реальной h_{uni}. Если окажется, что $h_{uni}\hat{h}_{uni}$, то это значит что в реальности мод больше одной. Т.е. нулевая гипотеза отвергается на уровне значимости α:

$$P(\text{multimodal}) = P(h_{uni} > \hat{h}_{uni}) \leq \alpha$$

(b) Используя бутстреп оцените следующую величину:

$$\hat{P}(h_{uni} > \hat{h}_{uni}) \approx \frac{1}{B} \sum_{b=1}^{B} \left(\hat{h}^b_{uni} \geq \hat{h}_{uni}\right)$$

Сэмплирование делайте из $\hat{p}_{K,\hat{h}_{uni}}(x)$, т.е. $X^* \sim X + \hat{h}_{uni} N(0, 1)$, где X – случайный элемент изначальной выборки.

N.B.: так как сэмплирование делается не из оригинальной эмпирической выборки, а из сглаженной, то дисперсия стала

выше. Подумайте как нужно скорректировать предложенную схему сэмплирования, чтобы дисперсия не изменилась?

Подсказка: для схемы сэмплирования $X^*a+b(\sim X+\hat{h}_{uni}N(0,1))$ найдите такие a и b, что первый и второй моменты этого распределения и эмпирического распределения совпадают.

(c) С каким уровнем значимости отвергается нулевая гипотеза?

5. (2 балла) Рассмотрим датасет по адресу https://vincentarelbundock.github.io/Rdatasets/csv/boot/cd4.csv

Датасет CD4 содержит информацию о 20 ВИЧ-инфицированных пациентах до и после года лечения на экспериментальном антивирусном лекарстве.

(a) Для коэффициента корреляции Пирсона между данными до и после лечения посчитайте 95% доверительный интервал следующими методами: нормальный, перцентильный, центральный и t-бутстрап. Для подсчёта дисперсии $\hat{\sigma}$ для t-bootstrap используйте следующую формулу: $\hat{\sigma}(r) = \sqrt{\frac{1-r^2}{n-2}}$.

Очень часто для работы бывает удобно применить нормализующее преобразование: $\frac{1}{2}\log\frac{1+r}{1-r}$. Сделайте это и посчитайте заново все интервалы. Что изменилось? Стали ли они более согласованными? Для подсчёта дисперсии для t-bootstrap в нормализованном виде используйте следующую оценку дисперсии: $\hat{\sigma}(r) = \frac{1}{\sqrt{n-3}}$

(b) В предыдущем пункте для t-bootstrap вы использовали некоторое аналитическое приближение для вычисления дисперсии корреляции. Теперь вам предстоит реализовать двойной бутстрап: над бутстрапными выборками по которым считается r делайте ещё бутстрап для оценки $\sigma(r)$. Сравните дисперсии

посчитанные аналитически и бутстрапом. Что вы заметили? Как изменились доверительные интервалы?

(c) После предыдущего пункта вам наверняка захотелось проверить все наши оценки на смещённость. Оцените смещение (bias) для коэффициента корреляции с помощью jackknife.

6. (4 балла) Фирма, занимающаяся маркетинговыми исследованиями, была нанята производителем автомобилей для определения вероятности того, что семья купит новую машину в течение следующего года. Была получена случайная выборка из 10 семей, у которых узнавали данные о годовом доходе. Опрос, проведённый 12 месяцев спустя, проверял купила ли семья автомобиль. Скачайте данные `car_reduced.table`.

   - Постройте логистическую регрессию для предсказания покупки в зависимости от дохода. Укажите проблему. Для понимания природы проблемы постройте логарифм профильной функции правдопободия для коэффициентов регрессии.
   - Для решения проблемы применяют регуляризированную фукнцию правдоподобия Фирта (Firth):

     $$\log \mathcal{L}^*(\beta) = \log \mathcal{L}(\beta) + \frac{1}{2} \log \det I(\beta)$$

     где $\mathcal{L}$ - станадартная функция правдоподобия, $I(\beta)$ - информационная матрица Фишера. В случае логистической регрессии с одним фактором, можем записать:

     $$I(\beta) = X^T W X,$$

     где X - матрица дизайна эксперимента(признаковое описание объектов), а W определяется по формуле:

     $$W = \mathrm{diag}(\hat{y}_i(1 - \hat{y}_i))$$

Проверьте, что такой способ решает проблему из первого пункта.

- Стандартной решением проблемы полной разделимости данных является получаение дополнительного набора данных. Вам удалось получить 23 новых примера, кроме того удалось добавить ещё одну переменную – возраст текущего автомобиля. Скачайте `car.table`, проверьте, что обычная логистическая регрессия работает в случае зависимости только от дохода. Сравните коэффициенты для обычной регрессии и регуляризованной. Обратите внимание, что этот этап можно выполнить двумя способами: напрямую оптимизируя регуляризованное правдоподобие или подсчитав значения правдоподобия на узлах решётки.
- Постройте двухфакторную модель.
- Для проверки качества постройте QQ-график остатков модели против нормального распределения. О чём говорит график? Можно ли его объяснить?